Analisis Perbandingan CNN dan SVM dalam Klasifikasi Tingkat Kepercayaan Diri Kandidat

Brenda Anastasya
Program Studi Teknik Informatika, Fakultas Teknologi Informasi
Universitas Tarumanagara
Jakarta, Indonesia
brenda.535240097@stu.untar.ac.id

***Abstrak*—** Penilaian tingkat kepercayaan diri kandidat dalam wawancara kerja secara manual umumnya masih bersifat subjektif dan berpotensi menghasilkan keputusan yang tidak konsisten. Penelitian ini bertujuan untuk mengotomatisasi proses klasifikasi tingkat kepercayaan diri kandidat menggunakan pendekatan *Computer Vision* melalui perbandingan performa model *Histogram of Oriented Gradients* (HOG) yang dikombinasikan dengan *Support Vector Machine* (SVM) dan model *Convolutional Neural Network* (CNN). *Dataset* yang digunakan terdiri atas 2.366 citra ekspresi wajah berlabel biner yang dibagi menggunakan metode *Stratified Train-Test Split* dengan rasio 80:20 dan dievaluasi melalui *Repeated Train-Test Split* sebanyak lima iterasi. Model SVM menggunakan ekstraksi fitur HOG dan kernel *Polynomial*, sedangkan model CNN dibangun dengan arsitektur *end-to-end* yang terdiri atas tiga *convolutional blocks* dan dua *dense layers*. Hasil eksperimen menunjukkan bahwa model HOG dan SVM dengan kernel *Polynomial* memberikan performa terbaik dengan rata-rata akurasi sebesar 0,7418 (74,18%), *precision* sebesar 0,7391, *recall* sebesar 0,7418, dan *F1-score* sebesar 0,7325. Sementara itu, model CNN memperoleh rata-rata akurasi sebesar 0,7194 (71,94%), *precision* sebesar 0,7176, *recall* sebesar 0,7194, dan *F1-score* sebesar 0,7073. Model HOG dan SVM juga menunjukkan stabilitas yang lebih baik dengan standar deviasi akurasi sebesar 0,0049 dibandingkan CNN sebesar 0,0096 serta memerlukan waktu pelatihan rata-rata sekitar 21,56 detik, jauh lebih singkat dibandingkan CNN yang membutuhkan rata-rata sekitar 1.066,60 detik. Berdasarkan hasil tersebut, kombinasi HOG dan SVM kernel *Polynomial* merupakan pendekatan yang lebih efektif dan efisien untuk klasifikasi tingkat kepercayaan diri kandidat pada kondisi *dataset* yang relatif terbatas.

Kata Kunci—*Klasifikasi, Kepercayaan diri, Histogram of Oriented Gradients, Support Vector Machine, Convolutional Neural Network*

I. PENDAHULUAN

Proses rekrutmen tenaga kerja merupakan salah satu pilar krusial dalam menentukan kualitas sumber daya manusia (SDM) di sebuah organisasi maupun industri [1]. Dalam proses wawancara kerja, penilaian terhadap kandidat tidak hanya didasarkan pada kompetensi teknis (*hard skills*) yang tertera pada *resume*, melainkan juga pada kompetensi perilaku (*soft skills*) [2][3]. Salah satu indikator *soft skills* yang menentukan keberhasilan wawancara adalah tingkat kepercayaan diri seseorang [4]. Biasanya evaluasi kepercayaan diri dilakukan secara manual oleh pewawancara melalui pengamatan visual terhadap bahasa tubuh, ekspresi wajah, arah pandangan mata (*eye movement)*, dan orientasi wajah (*face direction*). Namun, penilaian manusia bersifat subjektif, rentan terhadap bias, dan memerlukan waktu serta energi yang besar jika skala rekrutmen besar. Di era transformasi digital saat ini, pemanfaatan teknologi *Computer Vision* dan *Artificial Intelligence* (AI) menawarkan solusi objektif untuk melakukan otomatisasi analisis perilaku ini melalui ekstraksi dengan *frame images*.

Studi mengenai analisis perilaku dan emosi manusia menggunakan interaksi visual telah berkembang [5]. Pendekatan klasik dalam klasifikasi citra wajah umumnya mengandalkan ekstraksi fitur manual seperti *Local Binary Patterns* atau *Histogram of Oriented Gradients* yang kemudian diklasifikasikan menggunakan algoritma *Support Vector Machine* (SVM) [6][7][8]. SVM dikenal kuat dalam menangani data berdimensi tinggi dan efektif untuk klasifikasi objek, khususnya dalam mengenali karakteristik dan fitur pada citra wajah [9][10].

Di sisi lain, dalam *deep learning Convolutional Neural Network* (CNN) penggunaanya terus meningkat [11][12]. CNN dipilih karena secara natural dirancang untuk memproses data dua dimensi seperti citra, berkat adanya operasi konvolusi yang mampu mempertahankan informasi spasial dan hubungan antar piksel yang berdekatan [13]. *Dataset* "*Containing Frame Images of Indian Candidates during Interview for Confidence Level Estimation*" yang digunakan dalam penelitian ini terdiri dari 4.754 gambar dari 21 kandidat. Setiap kandidat dalam *dataset* ini diwakili oleh lebih dari 170 *frame* gambar dengan label biner berupa kondisi percaya diri (1) atau tidak percaya diri (0) yang diambil dari berbagai variasi pencahayaan, usia, dan latar belakang.

Meskipun penilaian visual secara otomatis memberikan efisiensi, implementasinya masih dihadapkan pada tantangan teknis terkait kompleksitas fitur visual dan kebutuhan komputasi. Penilaian tingkat kepercayaan diri tidak dapat didasarkan pada satu komponen tunggal, melainkan pada kombinasi dinamis dari berbagai fitur visual, seperti ekspresi wajah, pergerakan bola mata, dan orientasi kepala yang sangat rentan terhadap variasi pencahayaan serta latar belakang lingkungan. Kondisi ini memperumit pemilihan model akibat adanya *trade-off* antara akurasi dan efisiensi komputasi [14]. Model *deep learning* seperti *Convolutional Neural Network* (CNN) mampu memberikan akurasi tinggi namun membutuhkan sumber daya komputasi yang intensif [15][16][17]. Sebaliknya, arsitektur *machine learning* tradisional seperti *Support Vector Machine* (SVM) jauh lebih efisien, tetapi performanya sangat sensitif terhadap kualitas ekstraksi fitur mentah [18].

Ada juga tantangan pada subjektivitas proses pelabelan data (*data labeling*). Penerapan pelabelan biner yaitu percaya diri (1) atau tidak percaya diri (0) pada

karakteristik wajah berpotensi menimbulkan bias dan inkonsistensi data. Tantangan ini diperberat dengan kondisi *dataset* yang ternyata masih kotor, di mana ditemukan banyak citra duplikat serta sejumlah data yang belum dilabeli. Oleh karena itu, sistem klasifikasi ini menuntut model yang memiliki kemampuan generalisasi yang sangat tinggi. Tanpa adanya kapabilitas generalisasi yang memadai, model akan sangat rentan mengalami *overfitting*, di mana sistem hanya mampu mengenali data latih dengan baik namun gagal ketika diuji pada variasi wajah kandidat baru di lingkungan yang berbeda.

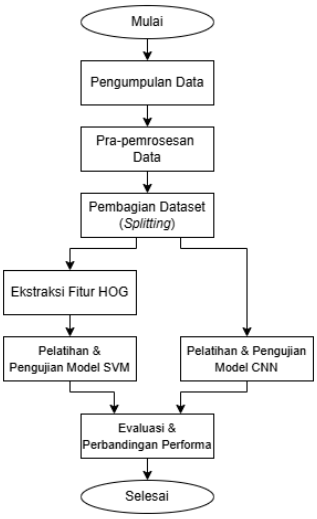
Penelitian ini bertujuan untuk mengimplementasikan arsitektur *Convolutional Neural Network* (CNN) dan algoritma *Support Vector Machine* (SVM) untuk mengklasifikasikan tingkat kepercayaan diri kandidat berdasarkan *dataset* gambar wawancara. Selain itu, penelitian ini juga diarahkan untuk menganalisis dan membandingkan performa kedua model melalui pemetaan *confusion matrix* serta perhitungan metrik evaluasi yang meliputi akurasi, *precision*, *recall*, dan *F1-score*. Evaluasi juga diperluas dengan mengukur nilai standar deviasi untuk menganalisis tingkat stabilitas performa model pada pengujian acak berulang, di samping mengukur efisiensi waktu komputasi saat proses *training* dan *inference*. Melalui analisis komparatif tersebut, penelitian ini diharapkan dapat menentukan pendekatan terbaik yang menawarkan keseimbangan optimal antara akurasi prediksi dan efisiensi sumber daya untuk kebutuhan sistem penilaian otomatis.

Hasil dari penelitian ini diharapkan dapat memberikan kontribusi baik secara teoretis maupun praktis. Secara teoretis, penelitian ini dapat memberikan referensi observasional dan literatur tambahan dalam domain *Computer Vision* mengenai studi komparatif antara arsitektur *deep learning* dan *shallow learning* untuk analisis perilaku manusia (*behavioral analysis*). Sementara itu, secara praktis, hasil penelitian ini dapat menyediakan fondasi teknologi bagi divisi *Human Resources* (HR) atau pengembang platform rekrutmen dalam membangun sistem penyaringan awal (*screening*) kandidat berbasis AI yang tidak hanya cepat dan terukur, tetapi juga objektif. Melalui penciptaan sistem rekrutmen yang objektif dan bebas dari bias subjektivitas manusia, penelitian ini turut mendukung pencapaian *Sustainable Development Goals* (SDGs), khususnya pada Poin 8 mengenai penyediaan pekerjaan yang layak dan pertumbuhan ekonomi melalui peningkatan kualitas SDM, serta Poin 10 dalam mengurangi kesenjangan dengan meminimalisasi potensi diskriminasi tidak sadar (*unconscious bias*) selama proses seleksi kerja.

II. METODE

A. Tahapan Penelitian

Penelitian ini menerapkan pendekatan eksperimental komparatif untuk mengestimasi tingkat kepercayaan diri kandidat melalui ekspresi wajah menggunakan dua arsitektur, yaitu *Support Vector Machine* (SVM) dan *Convolutional Neural Network* (CNN). Berdasarkan Gambar 1, alur metodologi secara sistematis diawali dengan tahapan pengumpulan *dataset* awal dari Mendeley Data. *Dataset* mentah yang diperoleh tersebut melewati proses pra-pemrosesan data terlebih dahulu meliputi pembersihan citra duplikat, eliminasi data tanpa label, serta penyesuaian dimensi untuk menjamin kualitas data sebelum memasuki fase pemodelan.



Gambar 1 Diagram Alur Metode Penelitian

Setelah data dinyatakan bersih, dilakukan pembagian data menjadi data latih (*training*) dan data uji (*testing*) menggunakan kombinasi metode *holdout* dan teknik *stratified shuffle* untuk menghindari risiko bias akibat ketidakseimbangan kelas. Alur penelitian kemudian masuk ke dalam tahap eksperimen paralel, di mana pada SVM dilakukan ekstraksi fitur geometri wajah secara manual menggunakan metode *Histogram of Oriented Gradients* (HOG) sebelum diklasifikasikan, sedangkan pada CNN proses ekstraksi fitur spasial dan klasifikasi berjalan secara otomatis secara *end-to-end*. Rangkaian metodologi ini diakhiri dengan tahapan evaluasi dan komparasi untuk mengukur serta membandingkan performa kedua model secara komprehensif berdasarkan parameter *Confusion Matrix* dan metrik efisiensi waktu komputasi.

B. Pengumpulan dan Pra-pemrosesan Data

Data yang digunakan dalam penelitian ini adalah *dataset* sekunder hasil eksperimen dengan judul "*Containing Frame Images of Indian Candidates during Interview for Confidence Level Estimation*" yang dipublikasikan melalui Mendeley Data [19]. *Dataset* mentah awal mencakup 4.754 citra berformat JPEG beresolusi tinggi yang diekstraksi dari rekaman video wawancara 21 kandidat etnis India dengan variasi latar belakang lingkungan *indoor* dan *outdoor* serta kondisi pencahayaan yang beragam. Pelabelan data pada *dataset* ini didasarkan pada tiga parameter utama perilaku visual, yaitu arah wajah (*face direction*), pergerakan mata (*eye movement*), dan ekspresi wajah (*facial expression*). Bobot terbesar dalam pelabelan diberikan pada parameter ekspresi wajah karena dinilai memiliki korelasi paling krusial dalam merepresentasikan tingkat kepercayaan diri seseorang secara visual. Skala pelabelan biner diterapkan pada dataset ini, di mana nilai 1 merepresentasikan kondisi percaya diri (*confident*) dan nilai 0 untuk kondisi tidak percaya diri (*unconfident*). Contoh citra kandidat yang percaya diri dan tidak percaya diri dapat dilihat pada Gambar 2.



Gambar 2 Contoh Citra Kandidat Percaya Diri dan Tidak Percaya Diri

Meskipun dataset ini kaya akan variasi demografi, ada beberapa isu teknis seperti data yang hilang (*missing data*), kesalahan pemrosesan, serta folder yang berisi citra duplikat. Oleh karena itu, penelitian ini melakukan seleksi ulang untuk menjaga validitas model. Dari total 21 kandidat awal, data dibatasi hanya pada 17 kandidat menjadi 4.080 citra, dan dengan mengeliminasi folder data yang tidak konsisten atau tidak memiliki label lengkap (*unlabeled data*), sehingga mereduksi jumlah sampel menjadi 2.366 citra bersih yang siap digunakan. Tahap pra-pemrosesan dilanjutkan dengan melakukan penyesuaian dimensi (*resize*) pada seluruh citra untuk menyeragamkan ukuran matriks input dan menekan *noise* visual.

Sebelum fase pelatihan model dimulai, *dataset* bersih tersebut dibagi (*data splitting*) menggunakan metode *holdout* dengan rasio 80% untuk data latih (*training*) sebanyak 1.892 citra dan 20% untuk data uji (*testing*) sebanyak 474 citra. Untuk memperkuat skenario pembagian ini dan mengantisipasi adanya bias klasifikasi akibat distribusi jumlah sampel antar-kelas yang tidak merata, diterapkan metode *Stratified 5-Iteration Shuffle*. Teknik ini memastikan pada setiap iterasi pengacakan, proporsi kelas target 0 dan 1 tetap terjaga secara seimbang dan representatif baik pada subset data latih maupun data uji, sehingga hasil evaluasi akhir model bersifat objektif.

C. *Algoritma Support Vector Machine dan Ekstraksi Fitur Histogram of Oriented Gradients*

Algoritma *Support Vector Machine* (SVM) tidak dapat mengolah data citra mentah secara langsung dengan efisien. Oleh karena itu, arsitektur ini membutuhkan tahapan ekstraksi fitur manual menggunakan metode *Histogram of Oriented Gradients* (HOG) sebelum proses klasifikasi dilakukan. Integrasi antara HOG dan SVM dipilih karena kemampuannya yang sangat tangguh dalam mengenali pola struktural, bentuk, dan tekstur lokal, yang dalam konteks penelitian ini direpresentasikan melalui ekspresi wajah, orientasi kepala, dan pergerakan mata kandidat [20].

Proses ekstraksi fitur menggunakan HOG dilakukan dengan menghitung nilai gradien pada setiap piksel. Nilai tersebut kemudian dikelompokkan ke dalam beberapa *cell* untuk membentuk histogram orientasi, lalu dinormalisasi dalam sejumlah *block* untuk menangani variasi pencahayaan. Pada eksperimen ini, citra *input* yang digunakan telah melalui tahap *preprocessing* berupa pengubahan dimensi menjadi berukuran 128 ×128 piksel.

Langkah pertama HOG diawali dengan menghitung vektor gradien untuk setiap piksel. Misalkan I_x dan I_y melambangkan nilai diferensial intensitas piksel tetangga pada arah horizontal (kiri dan kanan) dan vertikal (atas dan bawah). Magnitudo gradien (G) serta orientasi arah atau sudut inklinasi (θ) untuk setiap koordinat piksel ditentukan menggunakan (1) dan (2) sebagai berikut [14]:

$$G = \sqrt{I_x^2 + I_y^2} \quad (1)$$

$$\theta = \arctan\left(\frac{I_x}{I_y}\right) \quad (2)$$

Setelah nilai gradien diperoleh, citra dibagi ke dalam beberapa blok berukuran sama, di mana setiap blok dikerucutkan kembali menjadi sejumlah *cells* yang memiliki jumlah piksel seragam. Berdasarkan konfigurasi program, dimensi piksel per *cell* ditentukan sebesar 8×8 piksel, dan jumlah *cells* per *block* ditentukan sebesar 2×2. Untuk mengetahui total jumlah blok (n_{block}) yang terbentuk berdasarkan dimensi spasial citra, perhitungan dilakukan dengan menerapkan (3) [14]. Pada formula tersebut, w_i dan h_i merupakan lebar dan tinggi total dari citra *input* setelah dilakukan *resize,* w_b dan h_b merupakan jumlah *cells* dalam satu blok, lalu w_c dan h_c adalah dimensi dari satu *cell* dalam piksel.

$$n_{block} = \left(\frac{w_i - w_b \times w_c}{w_c} + 1\right) \times \left(\frac{h_i - h_b \times h_c}{h_c} + 1\right) \quad (3)$$

Di mana w_i = 128 dan h_i= 128 merupakan lebar dan tinggi citra *input*, w_b = 2 dan h_b= 2 merupakan jumlah *cells* horizontal dan vertikal dalam satu blok, sedangkan w_c = 8 dan h_c = 8 melambangkan ukuran lebar dan tinggi dari satu *cell*. Melalui perhitungan ini, diperoleh total blok sebanyak 15×15 = 225 blok dari satu citra wajah kandidat.

Langkah ketiga adalah melakukan pemetaan distribusi orientasi sudut ke dalam histogram. Ruang arah komputasi dibagi menjadi p buah bin. Menggunakan skema *unsigned* HOG dengan resolusi dimensi interval p = 9 yang mencakup sudut 0° hingga 180°, proses diskretisasi sudut inklinasi koordinat piksel $\alpha(x, y)$ ke dalam bentuk matriks karakteristik $B(x, y)$ diekspresikan pada (4) sebagai berikut [14]:

$$B(x, y) = round\left(\frac{p \times \alpha(x,y)}{\pi}\right) mod\ p \quad (4)$$

Untuk mengantisipasi variasi pencahayaan lokal pada citra wajah kandidat, sekelompok histogram dari *cells* yang berdekatan dikombinasikan menjadi satu kesatuan *block* untuk dilakukan normalisasi kontras menggunakan metode *L2-norm* dengan menyertakan konstanta epsilon (ϵ) yang bernilai sangat kecil untuk menghindari pembagian dengan angka nol. Skema normalisasi vektor fitur blok (v) diekspresikan melalui (5) sebagai berikut [14][21]:

$$v = \frac{v}{\sqrt{\|v\|_2^2 + \epsilon^2}} \quad (5)$$

Hasil akhir dari akumulasi seluruh histogram di setiap *block* ini menghasilkan satu kesatuan vektor fitur berdimensi tinggi yang merepresentasikan geometri wajah dan ekspresi kepercayaan diri kandidat. Vektor inilah yang kemudian diumpankan sebagai data *input* menuju algoritma klasifikasi SVM untuk memisahkan kelas target

$y_i \in \{0,1\}$, di mana nilai 0 untuk kondisi tidak percaya diri dan nilai 1 untuk kondisi percaya diri.

Untuk menemukan optimal *hyperplane* pembatas linier maupun non-linier yang memisahkan data ke dalam dua kelas target tersebut, fungsi keputusan akhir yang memanfaatkan parameter bobot optimal (α_i^*), nilai bias (b^*), serta fungsi basis kernel $K(x_i, x)$ diformulasikan melalui (6) sebagai berikut [14][21]:

$$f(x) = sgn\left(\sum_{i=1}^{l} \alpha_i^* y_i\, K(x_i, x) + b^*\right) \quad (6)$$

Pada (6), variabel l melambangkan jumlah data latih, dan sgn merupakan fungsi signum guna menentukan kelas prediksi akhir kandidat. Eksperimen pada penelitian ini melakukan evaluasi terhadap tiga variasi fungsi kernel $K(x_i, x)$ yang berbeda untuk mendapatkan performa terbaik, yaitu kernel *Linear*, *Polynomial*, dan *Radial Basis Function* (RBF), dengan parameter penalti *C* sebesar 1.0.

D. Algoritma Convolutional Neural Network

Arsitektur *Convolutional Neural Network* (CNN) dirancang untuk mengekstraksi fitur spasial secara otomatis dan bertahap langsung dari data citra mentah melalui operasi *end-to-end* [22]. Citra wajah input berdimensi 128×128 piksel dengan 3 saluran warna (RGB) diumpankan ke dalam jaringan konvolusi yang terdiri dari susunan lapisan terstruktur untuk mendeteksi karakteristik ekspresi kepercayaan diri kandidat.

Operasi utama pada lapisan konvolusi dilakukan dengan menggeser matriks kernel (*filter*) berukuran elemen tertentu di atas citra *input*. Hasil komputasi linear pada koordinat elemen piksel (*i, j*) di dalam *feature map* ke-*k* yang langsung diintegrasikan dengan fungsi aktivasi *Rectified Linear Unit* (ReLU) ditunjukkan melalui (7) sebagai berikut [21]:

$$x_{i,j}^k = \max\begin{pmatrix} 0, \sum_c \sum_m \sum_n w_{m,n}^{k,c} \times \\ I_{i+m,j+n}^c + b^k \end{pmatrix} \quad (7)$$

Di mana I^c melambangkan matriks citra *input* pada saluran ke-c, $w^{k,c}$ merupakan matriks bobot kernel filter ke-k untuk saluran ke -c, b^k adalah nilai bias lokal, serta indeks *m* dan *n* menyatakan dimensi spasial dari filter tersebut. Fungsi $\max(0,.)$ merepresentasikan aktivasi ReLU untuk mengeliminasi nilai gradien negatif menjadi nol untuk mempercepat proses konvergensi selama pelatihan [23].

Untuk mereduksi dimensi spasial dari *feature map* hasil konvolusi sekaligus mempertahankan informasi fitur yang paling dominan, jaringan menerapkan lapisan *Max Pooling*. operasi pengambilan nilai maksimum pada wilayah lokal berukuran *s*×*s* dieskpresikan melalui (8) [21]:

$$p_{i,j}^k = \max_{0 \le m,n < s} \left(x_{i.stride+m, j.stride+n}^k\right) \quad (8)$$

Di mana $p_{i,j}^k$ melambangkan nilai hasil reduksi pada koordinat (*i, j*), dan parameter *stride* menentukan langkah pergeseran jendela *pooling* di atas *feature map*. Perubahan dimensi spasial tinggi (H_{out})dan lebar (W_{out}) citra setelah melewati proses konvolusi maupun *pooling* dihitung memanfaatkan rumus yang didefinisikan melalui (9) dan (10) [21][24]:

$$H_{out} = \left[\frac{H_{in} - F_h + 2P}{S}\right] + 1 \quad (9)$$

$$W_{out} = \left[\frac{W_{in} - F_W + 2P}{S}\right] + 1 \quad (10)$$

Di mana H_{in} dan W_{in} melambangkan dimensi awal sebelum operasi, F_h dan F_w menyatakan tinggi dan lebar dari filter yang digunakan, *P* merupakan ketebalan parameter *padding*, dan *S* merepresentasikan nilai *stride*. Setelah melewati serangkaian lapisan konvolusi dan *pooling*, *feature map* dua dimensi ditransformasikan menjadi vektor satu dimensi melalui lapisan *Flatten*. Vektor ini kemudian dihubungkan ke lapisan *Fully Connected* (*Dense*). Total akumulasi *input* linear (*z*) pada sebuah neuron sebelum dipetakan menuju fungsi aktivasi keluaran biner dirumuskan melalui (11) sebagai berikut [21][24]:

$$z = \sum_{i=1}^{D} w_i . a_i + b \quad (11)$$

Di mana a_i melambangkan nilai aktivasi dari neuron pada lapisan sebelumnya, w_i adalah bobot penghubung antar neuron, *b* menyatakan parameter bias, dan *D* melambangkan dimensi total elemen vektor *input*. Nilai *z* ini kemudian dilewatkan pada fungsi aktivasi akhir seperti sigmoid untuk menghasilkan probabilitas prediksi klasifikasi biner tingkat kepercayaan diri kandidat.

E. Metode Evaluasi

Pengukuran kinerja dari arsitektur model klasifikasi tingkat kepercayaan diri kandidat dilakukan secara kuantitatif melalui analisis *confusion matrix*. Matriks ini memetakan tingkat kecocokan antara label kelas aktual pada data uji dengan hasil prediksi yang dihasilkan oleh algoritma *Support Vector Machine* (SVM) dan *Convolutional Neural Network* (CNN). Komparasi tersebut menghasilkan empat parameter dasar yang meliputi *True Positive* (TP) untuk representasi kelas percaya diri yang berhasil diprediksi dengan benar, *True Negative* (TN) untuk kelas tidak percaya diri yang berhasil diprediksi secara tepat, *False Positive* (FP) untuk kondisi di mana kelas tidak percaya diri salah dideteksi sebagai percaya diri, dan *False Negative* (FN) untuk kondisi saat kelas percaya diri salah diklasifikasikan sebagai tidak percaya diri. Berdasarkan nilai akumulasi keempat elemen tersebut, tingkat keberhasilan pemisahan biner dihitung secara komprehensif menggunakan matriks akurasi (*accuracy*), presisi (*precision*), *recall*, dan nilai *F1-score*.

Akurasi digunakan untuk mengukur persentase ketepatan prediksi model terhadap seluruh jumlah sampel data uji yang dievaluasi. Perhitungan nilai akurasi ditunjukkan melalui (12) sebagai berikut [25][26]:

$$Accuracy: \frac{TP+TN}{TP+TN+FP+FN} \quad (12)$$

Presisi mengukur tingkat ketepatan model dalam mengidentifikasi kelas positif untuk memastikan bahwa kandidat yang diprediksi berada dalam kondisi percaya diri memang benar-benar memiliki label aktual percaya diri, sehingga meminimalkan tingkat kesalahan deteksi positif

yang keliru. Formulasi untuk nilai presisi ditunjukkan melalui (13) sebagai berikut [25][26]:

$$Precision = \frac{TP}{TP+FP} \quad (13)$$

Recall mengukur kemampuan model dalam mengenali dan menjaring kembali seluruh sampel dari kelas positif yang terdapat di dalam dataset asli, yang bertujuan untuk menekan risiko adanya kandidat percaya diri yang terlewat atau salah teridentifikasi sebagai tidak percaya diri. Formula untuk menghitung nilai *recall* dirumuskan pada (14) sebagai berikut [25][26]:

$$Recall = \frac{TP}{TP+FN} \quad (14)$$

Sebagai indikator penyeimbang, nilai *F1-score* dihitung dengan mencari nilai *harmonic mean* yang mengombinasikan matriks presisi dan *recall*. Penggunaan nilai *F1-score* ini memberikan representasi performa yang lebih objektif dan valid, terutama untuk mengantisipasi ketidakseimbangan sebaran jumlah data (*imbalanced dataset*) antara kelas target 0 dan kelas target 1 pada subset data pengujian. Skema perhitungan untuk nilai *F1-score* didefinisikan melalui (15) sebagai berikut [25][26]:

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (15)$$

Penggunaan keempat metrik evaluasi tersebut bertujuan untuk memberikan gambaran yang menyeluruh dan jelas mengenai keandalan model dari berbagai sudut pandang statistik dalam membedakan kondisi percaya diri dan tidak percaya diri kandidat. Dengan membandingkan nilai *Accuracy*, *Precision*, *Recall*, dan *F1-Score*, penelitian ini dapat menentukan arsitektur mana yang paling optimal dan stabil dalam menangani klasifikasi visual ekspresi wajah kandidat. Seluruh hasil perhitungan metrik ini nantinya akan disajikan dalam bentuk tabel perbandingan performa serta visualisasi kurva pembelajaran dan *confusion matrix* untuk mempermudah analisis performa antara model kombinasi SVM dengan ekstraksi fitur HOG dan *end-to-end* CNN secara objektif.

Selain menggunakan metrik evaluasi tersebut, penelitian ini juga menerapkan perhitungan statistik berupa rata-rata (*mean*) dan standar deviasi (*standard deviation*) dari seluruh hasil pengujian yang berjalan selama 5 kali iterasi. Tingkat stabilitas model dinilai berdasarkan nilai standar deviasi dari akurasi pengujian, di mana model dikategorikan stabil jika memiliki nilai standar deviasi kurang dari 0,005, dikategorikan cukup stabil jika berada pada rentang 0,005 hingga 0,01, dan dikategorikan fluktuatif jika nilai standar deviasi melebihi 0,01. Penggunaan kriteria ambang batas ini bertujuan untuk memberikan gambaran komprehensif mengenai karakteristik model, sehingga pemilihan algoritma terbaik tidak hanya didasarkan pada keunggulan capaian angka metrik tertinggi, tetapi juga pada konsistensi performa yang dihasilkan di setiap variasi pembagian distribusi data [27].

III. HASIL DAN PAMBAHASAN

A. Penyebaran Data dan Hasil Pra-pemrosesan Citra

Data mentah setelah dilakukan seleksi terdiri dari 17 direktori folder representasi subjek kandidat yaitu selected_candidate_frames, mulai dari subjek C01 hingga C28, yang menghasilkan total sebanyak 4.080 citra mentah berformat JPEG. Seluruh citra tersebut memiliki resolusi spasial tinggi sebesar 658×1280 piksel dengan konfigurasi 3 warna RGB (*Red*, *Green*, *Blue*). Proses sinkronisasi dilakukan dengan mencocokkan nama citra terhadap pelabelan biner, di mana nilai 0 melambangkan kondisi tidak percaya diri dan nilai 1 melambangkan kondisi percaya diri, yang disediakan di dalam file CSV masing-masing kandidat. Setelah melakukan pembersihan data dengan menghapus seluruh baris yang tidak memiliki label dan melakukan rekonstruksi nama berkas berdasarkan kolom nomor urut citra, diperoleh selected_labeled_dataset dengan total 2.366 citra valid yang dapat digunakan untuk tahapan pengujian. Komposisi akhir sebaran kelas data setelah proses filtrasi adalah 1.469 citra untuk kelas 0 dan 897 citra untuk kelas 1.

Sebelum digunakan untuk model klasifikasi, seluruh citra melalui tahapan pra-pemrosesan untuk menjaga konsistensi dimensi matriks input. Langkah pertama melibatkan penyesuaian ukuran dimensi citra dari dimensi asli menjadi ukuran spasial standar 128×128 piksel. Langkah berikutnya adalah proses normalisasi nilai intensitas piksel dengan membagi setiap elemen matriks warna dengan nilai 255.0, sehingga mengubah skala warna menjadi interval [0.0, 1.0] untuk menstabilkan proses pembaruan bobot pada model pembelajaran.

B. Skenario Pengujian dan Pembagian Data

Eksperimen dilakukan menggunakan metode *Repeated Train-Test Split* yang berulang sebanyak 5 kali iterasi untuk menjamin stabilitas performa serta meminimalkan bias variasi pembagian data. Pada setiap iterasi, total data yang berjumlah 2.366 citra dibagi ke dalam proporsi 80% sebagai data latih dan 20% sebagai data uji menggunakan teknik *Stratified Train-Test Split*. *Stratified* diterapkan untuk menjaga rasio perbandingan jumlah kelas target 0 dan 1 tetap seimbang dan konsisten pada partisi data latih maupun data uji di setiap iterasi pengujian.

Dua arsitektur model diuji secara paralel menggunakan pembagian data tersebut, di mana model pertama adalah kombinasi HOG dan SVM yang menggunakan ekstraksi fitur *Histogram of Oriented Gradients* dengan parameter 9 orientasi arah bin, ukuran *cell* 8×8 piksel, dan ukuran *block* 2×2 *cells*. Lalu, dihasilkan representasi vektor geometri wajah kandidat berdimensi tinggi yang selanjutnya diklasifikasikan menggunakan algoritma SVM dengan nilai penalti C = 1.0. Untuk mencari konfigurasi optimal, pengujian dievaluasi pada tiga jenis fungsi kernel yaitu *Linear*, *Radial Basis Function* (RBF), dan *Polynomial*. Model kedua adalah *end-to-end* CNN yang memanfaatkan jaringan konvolusi untuk mengekstraksi fitur spasial secara otomatis dari citra berukuran 128×128×3 yang dilatih dengan parameter *hyperparameter* berupa jumlah *epoch* sebanyak 20, ukuran *batch* sebesar 32, dan tingkat pembelajaran bernilai 0.001.

C. Hasil Performa Model Klasifikasi

Eksperimen komparatif antara arsitektur Support Vector Machine (SVM) berbasis fitur HOG dan Convolutional Neural Network (CNN) menghasilkan metrik performa yang bervariasi dalam mengklasifikasikan tingkat kepercayaan diri kandidat wawancara. Pemaparan

hasil evaluasi diawali dengan penyajian data kuantitatif yang diukur melalui metrik *Confusion Matrix* serta efisiensi waktu komputasi dari kedua model saat menguji data bersih. Selanjutnya, analisis mendalam dilakukan untuk membedah karakteristik, kekuatan, serta kelemahan masing-masing arsitektur saat mengenali fitur-fitur visual ekspresi wajah dari subset data uji. Melalui pembahasan komparasi tersebut, dapat diidentifikasi model yang memberikan performa paling optimal dan efisien untuk diterapkan pada kasus estimasi tingkat kepercayaan diri secara otomatis.

1) Analisis Performa Support Vector Machine (SVM)

Berdasarkan pengujian biner menggunakan kombinasi ekstraksi fitur *Histogram of Oriented Gradients* (HOG) dan pengklasifikasi *Support Vector Machine* (SVM) pada skenario pembagian data 80:20, diperoleh karakteristik performa yang bervariasi di setiap fungsi kernel yang dapat dilihat pada Tabel 1, Tabel 2, dan Tabel 3.

TABEL1 PEFORMA SUPPORT VECTOR MACHINE LINEAR

Iterasi	5 kali iterasi dan pembagian data 80:20 pada kernel SVM Linear				
	Accuracy	*Precision*	*Recall*	*F1-Score*	*Train time (s)*
1	0,6941	0,6871	0,6941	0,6879	24,07
2	0,7046	0,7067	0,7046	0,7055	19,35
3	0,6793	0,6767	0,6793	0,6778	22,41
4	0,7068	0,7071	0,7068	0,7069	14,44
5	0,6667	0,6730	0,6667	0,6691	15,96

TABEL2 PEFORMA SUPPORT VECTOR MACHINE RBF

Iterasi	5 kali iterasi dan pembagian data 80:20 pada kernel SVM RBF				
	Accuracy	*Precision*	*Recall*	*F1-Score*	*Train time (s)*
1	0,7321	0,7269	0,7321	0,7241	26,03
2	0,7447	0,7469	0,7046	0,7293	20,75
3	0,7405	0,7362	0,7447	0,6778	15,17
4	0,7363	0,7325	0,7363	0,7257	14,85
5	0,7426	0,7381	0,7426	0,7376	17,18

TABEL3 PEFORMA SUPPORT VECTOR MACHINE POLYNOMIAL

Iterasi	5 kali iterasi dan pembagian data 80:20 pada kernel SVM Polynomial				
	Accuracy	*Precision*	*Recall*	*F1-Score*	*Train time (s)*
1	0,7384	0,7340	0,7384	0,7298	28,48
2	0,7489	0,7528	0,7489	0,7331	16,66
3	0,7384	0,7338	0,7384	0,7304	17,66
4	0,7447	0,7410	0,7447	0,7361	27,36
5	0,7384	0,7337	0,7384	0,7333	17,66

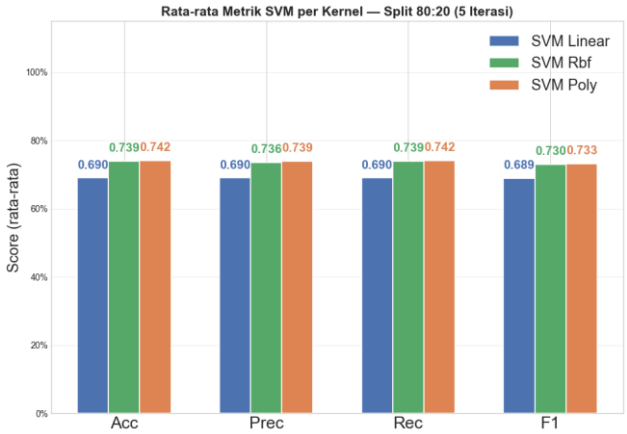
Proses ekstraksi HOG pada citra wajah kandidat menghasilkan dimensi fitur yang seragam dan konsisten di setiap iterasi, yaitu sebanyak 8.100 dimensi fitur. Nilai dimensi fitur yang tinggi ini menjadi fondasi bagi algoritma SVM untuk mendeteksi batas wilayah keputusan biner antara kondisi percaya diri dan tidak percaya diri. Dari hasil pengujian yang dievaluasi melalui lima kali iterasi pengujian acak berulang (*Repeated Train-Test Split*), nilai rata-rata (*mean*) capaian performa komprehensif dari ketiga variasi kernel yang diuji disajikan secara detail pada Tabel 4.

TABEL4 RINGKASAN RATA-RATA PEFORMA SUPPORT VECTOR MACHINE

Kernel	5 kali iterasi dan pembagian data 80:20				
	Accuracy	*Precision*	*Recall*	*F1-Score*	*Train time (s)*
Linear	0,6903	0,6901	0,6903	0,6895	19,25
RBF	0,7392	0,7361	0,7392	0,7298	18,79
Poly	0,7418	0,7391	0,7418	0,7325	21,56

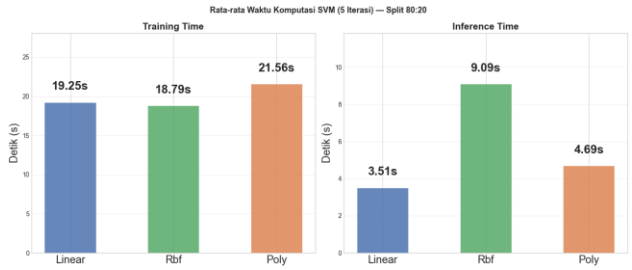
Analisis terhadap hasil Tabel 4 menunjukkan bahwa kernel *Polynomial* menempati peringkat tertinggi dengan nilai akurasi rata-rata sebesar 0,7418, nilai presisi sebesar 0,7391, nilai *recall* sebesar 0,7418, dan nilai *F1-score* mencapai 0,7325. Keberhasilan kernel *Polynomial* dalam mengungguli jenis kernel lainnya disebabkan oleh kemampuannya yang sangat adaptif dalam menangkap korelasi antar-fitur geometris wajah berskala bertingkat lewat perhitungan derajat polinomial non-linear [28]. Di posisi kedua, kernel RBF menunjukkan performa dengan capaian nilai akurasi rata-rata sebesar 0,7392 dan nilai *F1-score* sebesar 0,7298. Karakteristik non-linear pada kernel RBF mampu memetakan sebaran fitur geometri ekspresi kandidat yang tidak teratur ke dalam ruang dimensi baru secara fleksibel. Sebaliknya, kernel Linear menghasilkan performa paling rendah di antara ketiga pengujian dengan nilai akurasi rata-rata sebesar 0,6903 dan nilai *F1-score* sebesar 0,6895. Keterbatasan kernel Linear ini membuktikan bahwa batas keputusan garis lurus konvensional tidak cukup tangguh untuk variasi ekspresi wajah kompleks yang bersifat non-linear pada *dataset* kandidat.

Untuk memberikan ilustrasi visual yang representatif mengenai perbandingan seluruh parameter evaluasi dari ketiga fungsi kernel tersebut, grafik batang komparasi metrik performa SVM digambarkan secara komprehensif pada Gambar 3.



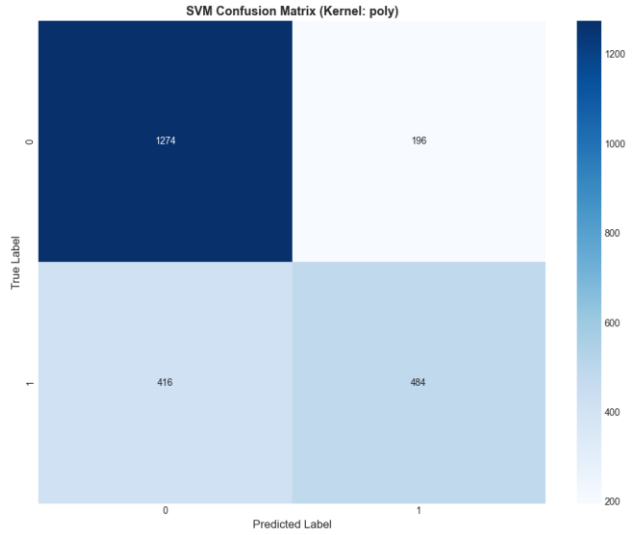
Gambar 3 Metrik Rata-Rata per Kernel Support Vector Machine

Selain meninjau aspek ketepatan klasifikasi, efisiensi waktu komputasi pemrosesan juga dianalisis untuk melihat kompleksitas jalannya algoritma. Berdasarkan pengujian, grafik perbandingan durasi pemrosesan untuk masing-masing model dipetakan melalui visualisasi kurva performa waktu komputasi pada Gambar 4.



Gambar 4 Visualisasi Rata-Rata Waktu Komputasi Support Vector Machine

Berdasarkan data pada Tabel 1 dan Gambar 4, kernel RBF mencatatkan waktu pelatihan rata-rata yang paling efisien yaitu selama 18,79 detik per iterasi, diikuti oleh kernel Linear selama 19,25 detik, sedangkan kernel *Polynomial* membutuhkan durasi paling lama yaitu mencapai 21,56 detik. Tingginya durasi pada kernel *Polynomial* berbanding dengan kompleksitas komputasi perkalian matriks berpangkat dalam mengolah 8.100 dimensi fitur HOG. Untuk menganalisis sebaran hasil deteksi biner akhir secara riil, total akumulasi nilai prediksi yang benar (*true*) maupun prediksi yang meleset (*false*) dari konfigurasi kernel *Polynomial* terbaik dipetakan melalui grafik matriks konfusi akumulatif seperti yang diperlihatkan pada Gambar 5.



Gambar 5 Visualisasi Confusion Matrix Support Vector Machine

Melalui hasil visualisasi matriks konfusi pada Gambar 5, dapat disimpulkan bahwa model kombinasi HOG dan SVM kernel *Polynomial* memberikan tingkat klasifikasi terbaik karena memiliki performa yang paling stabil dan seimbang dalam membedakan ekspresi percaya diri maupun tidak percaya diri dari kandidat di setiap variasi pembagian distribusi data uji. Nilai akurasi yang unggul di nilai 0,7418 serta efisiensi waktu pengujian yang relatif cepat dengan waktu 4,69 detik menjadikan kernel *Polynomial* sebagai arsitektur paling optimal dalam SVM untuk diterapkan dalam sistem penilaian otomatis tingkat kepercayaan diri kandidat wawancara.

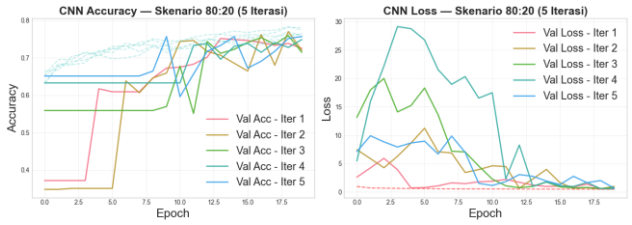
2) Analisis Performa Convolutional Neural Network (CNN)

Pengujian model berbasis jaringan konvolusi *end-to-end* yang berjalan menggunakan skenario pembagian data 80:20 dievaluasi melalui lima kali iterasi pengujian acak berulang (*Repeated Train-Test Split*) yang dapat dilihat pada Tabel 5.

TABEL5 PEFORMA CONVOLUTIONAL NEURAL NETWORK

Iterasi	5 kali iterasi dan pembagian data 80:20 pada CNN				
	Accuracy	*Precision*	*Recall*	*F1-Score*	*Train time (s)*
1	0,7236	0,7184	0,7236	0,7125	950,56
2	0,7321	0,7268	0,7321	0,7257	950,30
3	0,7215	0,7337	0,7215	0,6926	947,93
4	0,7110	0,7042	0,7110	0,7000	1068,60
5	0,7089	0,7047	0,7089	0,7059	1415,60

Berdasarkan eksperimen yang diperoleh pada Tabel 5, model CNN menghasilkan performa yang cukup kompetitif di setiap iterasinya, dengan capaian tertinggi pada iterasi kedua yang mencatatkan nilai akurasi sebesar 0,7321 dan nilai *F1-score* sebesar 0,7257. Karakteristik proses pembelajaran berkala dari jaringan ini terekam melalui visualisasi kurva nilai akurasi (*training and validation accuracy*) serta kurva nilai kerugian (*training and validation loss*) sepanjang *epoch* yang digambarkan pada Gambar 6.



Gambar 6 Akurasi & Loss per Epoch Untuk Setiap Iterasi Convolutional Neural Network

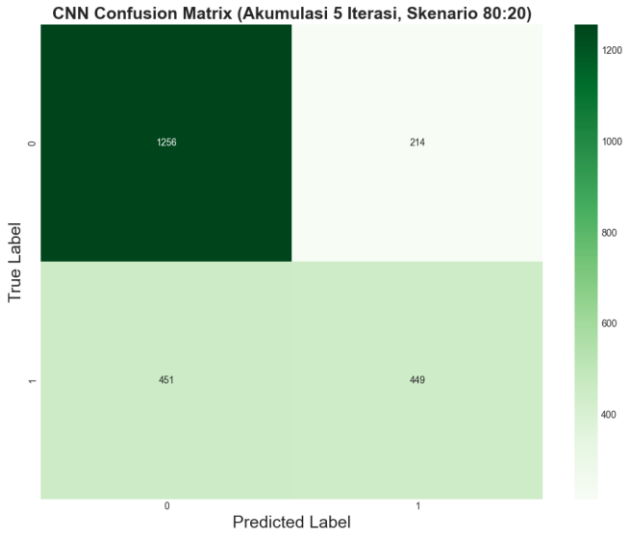
Melalui pengamatan grafik pada Gambar 6, garis putus-putus yang melambangkan data latih (*training*) dan garis solid yang melambangkan data uji (*validation*) bergerak beriringan secara stabil menuju titik konvergensi di setiap iterasi. Kurva *training* dan *validation* menunjukkan pola yang relatif berdekatan sehingga tidak terlihat indikasi *overfitting* yang signifikan. Kondisi tersebut membuktikan bahwa lapisan konvolusi berhasil mengekstraksi representasi visual fitur spasial ekspresi wajah kandidat dengan baik. Setelah seluruh tahapan pengujian selesai, ringkasan nilai rata-rata (*mean*) capaian kinerja dari arsitektur CNN ini disajikan secara komprehensif pada Tabel 6.

TABEL6 RINGKASAN RATA-RATA PEFORMA CONVOLUTIONAL NEURAL NETWORK

Algoritma	5 kali iterasi dan pembagian data 80:20

	Accuracy	*Precision*	*Recall*	*F1-Score*	*Train time (s)*
CNN	0,7194	0,7176	0,7194	0,7073	1066,60

Berdasarkan data pada Tabel 6, model CNN mencatatkan nilai akurasi rata-rata akhir sebesar 0,7194, nilai presisi sebesar 0,7176, nilai *recall* sebesar 0,7194, dan nilai *F1-score* sebesar 0,7073. Untuk menganalisis sebaran hasil deteksi biner serta akumulasi klasifikasi yang tepat maupun yang meleset pada data uji, hasil pemetaan matriks konfusi akumulatif dari kelima iterasi model CNN diperlihatkan pada Gambar 7.



Gambar 7 Visualisasi Confusion Matrix Convolutional Neural Network

Melalui visualisasi matriks konfusi pada Gambar 7, terlihat sebaran total prediksi benar (*True Positive* dan *True Negative*) serta prediksi salah (*False Positive* dan *False Negative*) yang dihasilkan oleh jaringan. Pola akumulasi ini menegaskan keandalan statistik arsitektur CNN dalam mengisolasi ciri visual ekspresi mikro wajah untuk membedakan kondisi percaya diri dan tidak percaya diri dari kandidat wawancara secara mandiri.

3) Analisis Komparatif dan Efesiensi Model

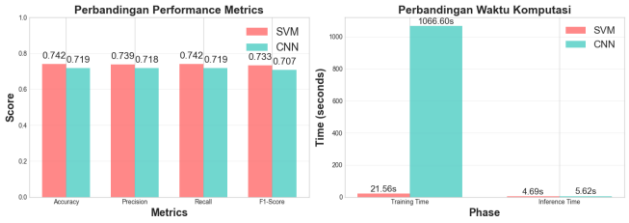
Tahapan akhir dari analisis ini melibatkan evaluasi komparatif untuk menentukan arsitektur terbaik dalam melakukan klasifikasi tingkat kepercayaan diri kandidat wawancara kerja. Proses komparasi dilakukan dengan menyejajarkan nilai rata-rata metrik evaluasi beserta nilai standar deviasi dari model kombinasi HOG dengan SVM kernel *Polynomial* sebagai konfigurasi terbaik SVM, dengan model *end-to-end* CNN yang terdiri atas arsitektur 3 *convolutional blocks* dan 2 *dense layers*. Ringkasan kuantitatif dari seluruh performa statistik dan durasi waktu eksekusi kedua model tersebut disajikan secara terperinci pada Tabel 7.

TABEL7 RINGKASAN PERBANDINGAN PERFORMA ANTAR ALGORITMA

Algoritma	**5 kali iterasi dan pembagian data 80:20**				
	Accuracy	*Precision*	*Recall*	*F1-Score*	*Train time (s)*
CNN	0,7194	0,7176	0,7194	0,7073	1066,60
SVM Poly	0,7418	0,7391	0,7418	0,7325	21,56

Berdasarkan data pada Tabel 7, model HOG dan SVM secara konsisten mengungguli model CNN pada seluruh metrik evaluasi utama yang diuji. Model HOG dan SVM mencatatkan keunggulan akurasi rata-rata sebesar 0,7418 (74,18%), sedangkan model CNN memperoleh nilai akurasi rata-rata sebesar 0,7194 (71,94%). Hal ini menunjukkan adanya selisih keunggulan performa sebesar 0,0224 (2,24%). Keunggulan ini juga terlihat pada parameter *F1-score*, di mana HOG dan SVM meraih nilai 0,7325 yang merepresentasikan keseimbangan prediksi biner yang lebih matang dibandingkan model CNN yang hanya dengan nilai 0,7073.

Pada *dataset* penelitian ini yang terdiri atas 2.366 citra, ekstraksi fitur berbasis HOG yang dikombinasikan dengan SVM memberikan performa yang lebih baik dibandingkan model CNN yang dibangun, sehingga menunjukkan bahwa pendekatan tersebut lebih sesuai untuk kondisi data yang relatif terbatas. Algoritma HOG yangmengekstraksi 8.100 dimensi fitur geometri ekspresi wajah secara deterministik berbasis orientasi gradien lokal terbukti jauh lebih efektif dalam mengekstrak ciri mikro ekspresi pada kondisi sampel data yang cenderung terbatas. Di sisi lain, model CNN yang dirancang secara mandiri memerlukan volume data latih berskala besar untuk mengoptimalkan ribuan bobot parameter konvolusinya agar terhindar dari bias klasifikasi. Representasi perbandingan angka metrik dari kedua model ini divisualisasikan secara jelas melalui grafik batang komparatif pada Gambar 8.



Gambar 8 Visualisasi Perbandingan Performa dan Waktu Komputasi

Selain aspek ketepatan prediksi, perbedaan yang paling kontras di antara kedua arsitektur terletak pada efisiensi waktu komputasi. Berdasarkan Tabel 7 dan Gambar 8, total waktu pemrosesan model HOG dan SVM hanya memerlukan durasi keseluruhan selama 26,2523 detik, sedangkan model CNN menghabiskan waktu hingga 1.072,2 detik. Hal ini menunjukkan bahwa model CNN membutuhkan waktu pelatihan sekitar 40 kali lebih lama dibandingkan SVM atau memiliki selisih waktu latih sebesar 1.046 detik lebih lama dibandingkan model SVM. Durasi pelatihan CNN yang tinggi disebabkan oleh kebutuhan operasi konvolusi perkalian matriks berulang dan pembaruan bobot jaringan saraf (*backpropagation*) secara iteratif sepanjang *epoch*.

Setelah membandingkan nilai rata-rata dan waktu komputasi, analisis stabilitas model dilakukan secara lebih mendalam menggunakan parameter standar deviasi (*standard deviation*) dari lima kali iterasi pengujian acak berulang (*Repeated Train-Test Split*) yang dapat dilihat pada Tabel 8. Melalui hasil perhitungan sebaran statistik, diperoleh nilai akurasi akhir untuk model HOG dan SVM sebesar 0,7418 ± 0,0049, sedangkan model CNN

mencatatkan nilai sebesar 0,7194 ± 0,0096. Pola sebaran variansi yang serupa juga terjadi pada metrik lain, di mana nilai *F1-score* untuk SVM berada pada angka 0,7325 ± 0,0025 sementara CNN berada pada rentang 0,7073 ± 0,0126.

TABEL8 STANDAR DEVIASI METRIK 5 ITERASI, SPLIT 80:20

Algoritma	5 kali iterasi dan pembagian data 80:20			
	Accuracy	***Precision***	***Recall***	***F1-Score***
CNN Mean	0,7194	0,7176	0,7194	0,7073
SVM Poly Mean	0,7418	0,7391	0,7418	0,7325
CNN Std	0,0096	0,0132	0,0096	0,0126
SVM Poly Std	0,0049	0,0083	0,0049	0,0025

Merujuk pada kriteria ambang batas stabilitas yang telah ditentukan sebelumnya, model HOG dan SVM dikategorikan sebagai model yang stabil karena memiliki nilai standar deviasi akurasi sebesar 0,0049, yang berada di bawah ambang batas minimal ($std < 0{,}005$). Sebaliknya, model CNN dikategorikan sebagai model yang cukup stabil karena nilai standar deviasi akurasinya berada pada angka 0,0096, yang memenuhi interval rentang stabilitas menengah ($0{,}005 \leq std \leq 0{,}01$). Tingginya nilai deviasi pada CNN ini mengindikasikan bahwa model jaringan saraf tersebut cenderung lebih sensitif dan fluktuatif terhadap skema pengacakan pembagian distribusi data latih dan uji di setiap iterasinya dibandingkan dengan SVM.

Kombinasi model HOG dan SVM dengan kernel *Polynomial* terpilih sebagai arsitektur paling optimal dalam mengestimasi tingkat kepercayaan diri kandidat wawancara kerja. Model ini terbukti unggul secara komprehensif karena menghasilkan akurasi tertinggi, stabilitas statistik yang paling kokoh, serta efisiensi waktu komputasi yang lebih cepat dibandingkan arsitektur CNN.

IV. KESIMPULAN DAN SARAN

Kesimpulan dari penelitian ini menunjukkan bahwa seluruh tujuan penelitian yang telah dirumuskan berhasil tercapai dengan baik melalui implementasi dan pengujian komparatif dua arsitektur untuk klasifikasi tingkat kepercayaan diri kandidat wawancara kerja. Berdasarkan serangkaian eksperimen pengujian acak berulang (*Repeated Train-Test Split*) sebanyak lima kali iterasi pada dataset biner yang terdiri atas 2.366 citra ekspresi wajah, model kombinasi *Histogram of Oriented Gradients* (HOG) dan *Support Vector Machine* (SVM) dengan fungsi kernel Polynomial terbukti sebagai arsitektur yang paling optimal. Model HOG dan SVM kernel *Polynomial* tidak hanya menghasilkan ketepatan prediksi tertinggi dengan rata-rata nilai akurasi sebesar 0,7418 (74,18%) dan *F1-score* sebesar 0,7325, melainkan juga menunjukkan konsistensi performa yang superior dengan nilai standar deviasi akurasi sebesar 0,0049 yang masuk ke dalam kategori model yang stabil. Selain itu, model SVM menawarkan efisiensi biaya komputasi dengan total waktu pemrosesan hanya selama 26,3 detik, mengungguli model *end-to-end* CNN yang mengalami *computational bottleneck* dengan durasi pelatihan mencapai 1.066,6 detik dan tingkat stabilitas yang lebih rendah yaitu dengan nilai standar deviasi sebesar 0,0096. Keberhasilan ini menegaskan bahwa penggunaan ekstraksi fitur geometri berbasis HOG jauh lebih tangguh untuk mengeksplorasi ciri visual mikro ekspresi wajah kandidat pada kondisi ketersediaan data latih yang terbatas.

Berdasarkan hasil capaian tersebut, beberapa saran untuk penelitian lanjutan yang dapat direkomendasikan adalah pengembangan *volume* dan variasi *dataset* visual kandidat secara lebih masif, serta peningkatan kualitas pelabelan data agar lebih terisi secara menyeluruh untuk menghindari adanya label yang kosong atau hilang (*missing labels*), sehingga model *deep neural network* seperti CNN dapat dilatih secara lebih optimal tanpa mengalami bias distribusi kelas. Selain itu, riset berikutnya dapat mengintegrasikan pendekatan multimodal dengan menggabungkan fitur visual ekspresi wajah dari HOG bersama dengan fitur auditori (intonasi suara) kandidat dan fitur tekstual (analisis linguistik jawaban) untuk meningkatkan akurasi deteksi psikologis secara lebih komprehensif. Terakhir, optimasi *hyperparameter* secara otomatis pada arsitektur CNN atau penggunaan metode *transfer learning* dengan model *pretrained* berskala besar juga patut dieksplorasi untuk mereduksi durasi waktu komputasi pelatihan jaringan tanpa mengorbankan kualitas performa klasifikasi akhir.

UCAPAN TERIMAKASIH

Ucapan Terima Kasih disampaikan kepada Dosen Pengampu mata kuliah *Machine Learning* yang telah memberikan persetujuan topik serta arahan awal bagi penulis dalam memulai penelitian ini. Penulis juga bersyukur atas kesempatan dan ruang akademik yang diberikan sepanjang semester, sehingga penulis dapat menyelesaikan seluruh tahapan eksperimen, pengolahan data, hingga penyusunan artikel ini hingga selesai.

Referensi

[1] Kristanto, M. Saragih, and D. Triyanti Purba, "Pengaruh Perencanaan Sumber Daya Manusia, Rekrutmen Dan Seleksi Karyawan Terhadap Kinerja Karyawan PT. Sumber Aksara Mas," *Manajemen: Jurnal Ekonomi*, vol. 6, no. 1, pp. 55–66, May 2024, doi: 10.36985/qn79b341.

[2] I. I. Putri, B. Sinring, A. Arfah, T. Alwany, and R. R. Taufan, "Pengaruh Hard Skill dan Soft Skill Terhadap Kinerja Karyawan," *Center of Economic Students Journal*, vol. 6, no. 2, pp. 223–238, Apr. 2023, doi: 10.56750/csej.v6i2.588.

[3] S. Ufia, A. D. Nugroho, and T. Wahjoedi, "Meningkatkan Kompetensi Mahasiswa melalui Program Magang Sebagai Upaya Peningkatan Hard Skill dan Soft Skill," *Journal of Knowledge and Collaboration*, vol. 1, no. 2, pp. 39–47, Jun. 2024, doi: 10.59613/97dmmj73.

[4] F. F. Al Fahmi *et al.*, "Meningkatkan Kepercayaan Diri Mahasiswa Melalui Public Speaking di Ranah Akademik dan Profesional," *Malewa: Journal of Multidisciplinary Educational Research*, vol. 3, no. 1, pp. 30–42, Jun. 2025, doi: 10.61683/jome.v3i1.217.

[5] J. Kristiyono and A. Nurrosyidah, "ANALISIS PERILAKU PENCARIAN INFORMASI DI INTERNET MELALUI FITUR VISUAL SEARCH," *Jurnal SCRIPTURA*, vol. 11, no. 2, pp. 96–104, Dec. 2021, doi: http://dx.doi.org/10.9744/scriptura.4.1.1-9.

[6] R. Kosasih and C. Daomara, "Pengenalan Wajah dengan Menggunakan Metode Local Binary Patterns Histograms (LBPH)," *JURNAL MEDIA INFORMATIKA BUDIDARMA*, vol. 5, no. 4, p. 1258, Oct. 2021, doi: 10.30865/mib.v5i4.3171.

[7] O. Pribadi, "APLIKASI PENGENALAN WAJAH MENGGUNAKAN ALGORITMA HAAR CASCADE CLASSIFIER DAN LOCAL BINARY PATTERN HISTOGRAM," *Jurnal TIMES*, vol. 12, no. 1, pp. 40–47, Sep. 2023, doi: 10.51351/jtm.12.1.2023691.

[8] M. F. Abdi, . K., and M. P. Kurniawan, “LOCAL BINARY PATTERN UNTUK EKTRAKSI TEKSTUR GAMBAR WAJAH MENGGUNAKAN MASKER DAN TANPA MASKER,” *Technologia : Jurnal Ilmiah*, vol. 13, no. 2, p. 108, Apr. 2022, doi: 10.31602/tji.v13i2.6275.

[9] B. Darma Irawan, R. Kurniawan, and Y. Arie Wijaya, “OPTIMALISASI MODEL KLASIFIKASI MENGGUNAKAN ALGORITMA SUPPORT VECTOR MACHINE PADA CITRA BRAIN TUMOR,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 9, no. 2, pp. 3493–3500, Apr. 2025, doi: 10.36040/jati.v9i2.13211.

[10] H. Eldo, A. Ayuliana, D. Suryadi, G. Chrisnawati, and L. Judijanto, “Penggunaan Algoritma Support Vector Machine (SVM) Untuk Deteksi Penipuan pada Transaksi Online,” *Jurnal Minfo Polgan*, vol. 13, no. 2, pp. 1627–1632, Oct. 2024, doi: 10.33395/jmp.v13i2.14186.

[11] D. I. Swasono, M. A. R. Wijaya, and M. A. Hidayat, “Klasifikasi Penyakit pada Citra Buah Jeruk Menggunakan Convolutional Neural Networks (CNN) dengan Arsitektur Alexnet,” *INFORMAL: Informatics Journal*, vol. 8, no. 1, p. 68, Apr. 2023, doi: 10.19184/isj.v8i1.38563.

[12] C. Nisa and F. Candra, “Klasifikasi Jenis Rempah-Rempah Menggunakan Algoritma Convolutional Neural Network,” *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 4, no. 1, pp. 78–84, Dec. 2023, doi: 10.57152/malcom.v4i1.1018.

[13] J. Alberto and D. Hermanto, “Bird Species Classification Using CNN Method and ResNet-50 Architecture,” *JATISI (Jurnal Teknik Informatika dan Sistem Informasi)*, vol. 10, no. 3, pp. 34–46, Sep. 2023.

[14] P. N. Huu and T. Phung Ngoc, “Hand Gesture Recognition Algorithm Using SVM and HOG Model for Control of Robotic System,” *Journal of Robotics*, vol. 2021, pp. 1–13, Jun. 2021, doi: 10.1155/2021/3986497.

[15] I. R. Alfiandi, Gunawan, M. R. Fadhil, and R. Samsinar, “Analisis Performa Convolutional Neural Network (CNN) dan Naive Bayes dalam Face Recognition: Akurasi dan Kompleksitas,” *HUBISINTEK*, vol. 5, no. 1, pp. 284–294, Jan. 2025.

[16] I. Wirabowo and I. Susilawati, “Implementasi Convolution Neural Network (CNN) untuk Deteksi Penyakit pada Daun Jagung Berbasis Citra Digital,” *Jurnal Pustaka Data (Pusat Akses Kajian Database, Analisa Teknologi, dan Arsitektur Komputer)*, vol. 5, no. 1, pp. 233–241, Jun. 2025, doi: 10.55382/jurnalpustakadata.v5i1.1046.

[17] A. Alem and S. Kumar, “End-to-End Convolutional Neural Network Feature Extraction for Remote Sensed Images Classification,” *Applied Artificial Intelligence*, vol. 36, no. 1, Dec. 2022, doi: 10.1080/08839514.2022.2137650.

[18] M. R. Tri Wardhana, A. Septiandy, I. Sintani, V. Saprilliana Anugrah, S. Dwi Cahya, and W. Widiatry, “SYSTEMATIC REVIEW PENGGUNAAN ISOLATION FOREST DAN SUPPORT VECTOR MACHINE UNTUK ANOMALY DETECTION,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 10, no. 1, pp. 50–56, Jan. 2026, doi: 10.36040/jati.v10i1.16602.

[19] S. Jain, N. Satav, A. Kakade, and R. Shastri, “Dataset Containing Frame Images of Indian Candidates during Interview for Confidence Level Estimation,” Apr. 13, 2023, *Mendeley Data*: 2. doi: 10.17632/dk2h3vhnnx.2.

[20] Muhammad Adeva, Naila Jinan Gaisani, and I Gusti Ngurah Karunya Pratama, “Klasifikasi Citra Batik Banyumasan Menggunakan Ekstraksi Fitur HOG, Reduksi Dimensi PCA, dan Klasifikasi SVM,” *Jurnal Ilmiah Teknologi Informasi dan Robotika*, vol. 7, no. 2, pp. 39–45, Dec. 2025, doi: 10.33005/jifti.v7i2.193.

[21] K. Li, H. Yu, Y. Xu, and X. Luo, “Detection of Marine Oil Spills Based on HOG Feature and SVM Classifier,” *J. Sens.*, vol. 2022, pp. 1–11, Dec. 2022, doi: 10.1155/2022/3296495.

[22] N. Anggraini, D. Arman Prasetya, and T. Trimono, “PREDIKSI HARGA SAHAM SEKTOR ENERGI MENGGUNAKAN METODE SPATIAL TEMPORAL ATTENTION-BASED CONVOLUTIONAL NETWORK BERDASARKAN DATA TEKS DAN NUMERIK,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 9, no. 3, pp. 3872–3880, May 2025, doi: 10.36040/jati.v9i3.13443.

[23] A. A. Elngar *et al.*, “Image Classification Based On CNN: A Survey,” *Journal of Cybersecurity and Information Management (JCIM)*, vol. 6, no. 1, pp. 18–50, Apr. 2021.

[24] Fawaidul Badri, M. Taqijuddin Alawiy, and Eko Mulyanto Yuniarno, “DEEP LEARNING ARCHITECTURE BASED ON CONVOLUTIONAL NEURAL NETWORK (CNN) IN IMAGE CLASSIFICATION,” *Jurnal Ilmiah Kursor*, vol. 12, no. 2, pp. 83–92, Dec. 2023, doi: 10.21107/kursor.v12i2.349.

[25] E. Helmud, E. Helmud, F. Fitriyani, and P. Romadiana, “Classification Comparison Performance of Supervised Machine Learning Random Forest and Decision Tree Algorithms Using Confusion Matrix,” *Jurnal Sisfokom (Sistem Informasi dan Komputer)*, vol. 13, no. 1, pp. 92–97, Feb. 2024, doi: 10.32736/sisfokom.v13i1.1985.

[26] M. W. Dwinanda, N. Satyahadewi, and W. Andani, “CLASSIFICATION OF STUDENT GRADUATION STATUS USING XGBOOST ALGORITHM,” *BAREKENG: Jurnal Ilmu Matematika dan Terapan*, vol. 17, no. 3, pp. 1785–1794, Sep. 2023, doi: 10.30598/barekengvol17iss3pp1785-1794.

[27] S. Sa’adah, A. Y. R. Wulandari, A. Fikriyah, and L. K. Muharrami, “Analisis Kemampuan Berpikir Kritis Siswa SMP Materi Pemanasan Global Dengan Sola Berbasis Pendekatan Socioscientific Issues (SSI),” *Natural Science Education Research*, vol. 4, no. 3, pp. 231–241, Mar. 2022, doi: 10.21107/nser.v4i3.8516.

[28] S. Saifuddin, L. Azhari, E. Widarti, and W. Wartono, “Evaluasi Kinerja Kernel Linear, RBF, dan Polynomial pada Model Support Vector Machine untuk Prediksi Risiko Hipertensi,” *Jurnal Ilmiah FIFO*, vol. 17, no. 2, p. 192, Nov. 2025, doi: 10.22441/fifo.2025.v17i2.008.